گزارش فاز اول:

طبقه‌بندی چندوجهی گونه‌های قارچ و تمایز گونه‌های سمی از خوراکی با تصمیم‌گیری آگاه از ریسک تحت تغییر دامنه جغرافیایی

امیرمحمد غیاثوند (شماره دانشجویی: 403100257) | **مجموعه داده:** مشاهدات و تصاویر واقعی iNaturalist v1 API |

تگ : `phase-1`

---

۱. صورت‌بندی مسئله و تفکر استراتژیک با داده

شناسایی گونه‌های قارچ‌های وحشی در طبیعت (Mushroom Foraging & Biodiversity Monitoring) یکی از چالش‌برانگیزترین و پرریسک‌ترین مسائل در حوزه علوم شهروندی (Citizen Science) و بینایی ماشین است. چالش بنیادین در این دامنه، وجود **گونه‌های هم‌شکل یا بدل (Morphological Look-alikes)** است؛ یعنی گونه‌هایی که از نظر ویژگی‌های ظاهری کلان (رنگ کلاهک، فرم ساقه یا ساختار تیغه‌ها) شباهت شدیدی به قارچ‌های خوراکی محبوب دارند، اما حاوی سموم کشنده‌ای نظیر آماتوکسین هستند (مانند قارچ کشنده *Amanita phalloides* یا *Galerina marginata*).

در یک مسئله طبقه‌بندی استاندارد یادگیری ماشین، تمامی خطاهای مدل وزن یکسانی دارند. اما در سیستم‌های پشتیبان تصمیم‌گیری برای شناسایی قارچ‌ها، **ماتریس هزینه خطا به شدت نامتقارن است:** پیش‌بینی اشتباه یک قارچ کشنده به عنوان «خوراکی» (خطای بحرانی یا Critical False-Safe) می‌تواند منجر به مسمومیت حاد کبدی و مرگ شود، در حالی که پیش‌بینی محافظه‌کارانه یک قارچ خوراکی به عنوان «مشکوک/سمی» صرفاً منجر به احتیاط بیشتر کاربر یا ارجاع نمونه به متخصص قارچ‌شناسی می‌گردد. بنابراین، هدف این پروژه صرفاً بیشینه‌سازی دقت خام نیست؛ بلکه طراحی یک سیستم پشتیبان تصمیم‌گیری چندوجهی و آگاه از ریسک است که با ادغام تصویر و فراداده‌های مکانی-زمانی، احتمالات خروجی را کالیبره کرده و ریسک خطاهای مرگبار را مهار کند.

۲. طرح سه سؤال اولیه و استدلال انتخاب سؤال اصلی پروژه

در ابتدای فاز اول، سه سؤال تحلیلی و پیش‌بینی قابل اجرا بر روی زیرمجموعه داده واقعی iNaturalist طراحی و امکان‌سنجی شدند تا سؤال نهایی پروژه با استدلال علمی انتخاب گردد:

- **سؤال کاندید اول (تمرکز بر میان‌برهای مکانی-زمانی / Shortcut Learning):** تا چه حد متغیرهای مکانی و زمانی (عرض و طول جغرافیایی و ماه مشاهده) به تنهایی و بدون مشاهده تصویر می‌توانند گونه قارچ را پیش‌بینی کنند و چه خطری از نظر یادگیری میان‌برهای شکننده ایجاد می‌کنند؟ *(ارزیابی: این سؤال برای ممیزی خط مبنا ضروری است اما به تنهایی بخش بصری و تصمیم‌گیری ریسک را پوشش نمی‌دهد؛ لذا به عنوان زیرمسئله در فاز ۱ و ۳ حفظ شد.)*
- **سؤال کاندید دوم (تمرکز بر تغییر دامنه جغرافیایی / Geographic Domain Shift):** مدلی که صرفاً بر روی مشاهدات قارچ‌های آمریکای شمالی آموزش دیده است، هنگام ارزیابی روی مشاهدات قاره اروپا چه میزان افت عملکرد و تغییر در کالیبراسیون را تجربه می‌کند؟ *(ارزیابی: این سؤال محور اصلی ارزیابی تعمیم‌پذیری در فاز ۴ است اما باید با چارچوب کلی مدل‌سازی ترکیب شود.)*

سؤال کاندید سوم — سؤال اصلی و منتخب پروژه: «چگونه می‌توان با ادغام بازنمایی‌های تصویری (از شبکه‌های عصبی از پیش آموزش‌دیده) و فراداده‌های مکانی-زمانی در حضور توزیع دنباله بلند، دقت تشخیص ۴۰ گونه قارچ را بهبود بخشید و با کالیبراسیون عدم قطعیت و اعمال قاعده تصمیم‌گیری حساس به هزینه (همراه با گزینه خودداری از تصمیم در موارد مبهم)، نرخ خطای بحرانی (تشخیص قارچ کشنده به عنوان خوراکی) را حتی تحت تغییر دامنه جغرافیایی از آمریکای شمالی به اروپا به حداقل رساند؟»

۳. شناخت منشأ داده، تعریف زیرمجموعه علمی و معماری جداول

داده‌های این پروژه به صورت ۱۰۰٪ واقعی از طریق **API رسمی iNaturalist v1** استخراج شده‌اند. این داده‌ها **مشاهداتی (Observational)** و حاصل ثبت گزارش‌های شهروند-دانشمندان در طبیعت (In-the-wild) هستند، نه حاصل یک آزمایش کنترل‌شده آزمایشگاهی. در نتیجه، داده‌ها به طور طبیعی دارای سوگیری گزارش‌دهی مکانی (تراکم بالاتر در مجاورت شهرها و مسیرهای طبیعت‌گردی)، سوگیری زمانی (ثبت بیشتر در فصول معتدل) و سوگیری جذابیت بصری هستند.

تعریف علمی زیرمجموعه (Subset Definition): زیرمجموعه انتخابی شامل **۴۰ گونه شاخص از رده *Agaricomycetes*** است که به طور هدفمند در ۱۰ گروه شباهت ظاهری (Look-alike Guilds) انتخاب شده‌اند و شامل **۱۲ گونه کشنده و بسیار سمی (`Deadly_Toxic`)**، **۸ گونه غیرخوراکی یا سمی خفیف (`Inedible_MildToxic`)** و **۲۰ گونه خوراکی مرغوب (`Edible`)** می‌باشند. مشاهدات به رکوردهای دارای درجه کیفی تأییدشده علمی (`quality_grade = research`) در بازه زمانی ژانویه ۲۰۲۰ تا دسامبر ۲۰۲۵ در دو قاره **آمریکای شمالی** (دامنه آموزش و آزمون داخلی) و **اروپا** (دامنه آزمون تغییر جغرافیایی) محدود شده‌اند.

نام جدول / فایل در پایپ‌لاین	سطح و کلید اصلی	تعداد رکورد واقعی	متغیرهای کلیدی و نقش در زنجیره تحلیل
`species_toxicity_metadata.csv`	گونه (`taxon_id`)	40 گونه	شناسه رسمی iNaturalist، نام علمی و عمومی، خانواده زیستی، کلاس سمیت، سطح ریسک و گروه ظاهری (Look-alike Guild).
`fungi_observations_raw.csv`	مشاهده (`observation_uuid`)	7,366 مشاهده	شناسه مشاهده‌گر (`observer_id`)، تاریخ و ساعت ثبت، مختصات GPS، دقت مکانی، قاره، تعداد عکس و مسیر فایل تصویر محلی.
`fungi_photos_raw.csv`	تصویر (`photo_id`)	15,595 تصویر	ارتباط یک‌به‌چند با مشاهده، ترتیب عکس، ابعاد تصویر (عرض و ارتفاع)، آدرس سرور و کد مجوز انتشار (License).
`data/raw/images/*.jpg`	فایل تصویر (`.jpg`)	7,366 فایل	تصاویر واقعی دانلود و راستی‌آزمایی شده روی دیسک برای استخراج بازنمایی‌های بصری با PyTorch در فازهای بعدی.

۴. ممیزی ساختار سلسله‌مراتبی و کیفیت داده (Data Quality Audit)

برخلاف دیتاست‌های ساده جدولی، داده‌های iNaturalist دارای ساختار سلسله‌مراتبی چهارسطحی (`Observer → Observation → Photo → Taxon`) هستند. ممیزی دقیق ساختار و کیفیت بر روی ۷,۳۶۶ مشاهده واقعی دریافتی، یافته‌های کمی زیر را آشکار ساخت:

شاخص ممیزی ساختار و کیفیت داده (Audit Metric)	مقدار کمی در داده واقعی	تصمیم فنی و نحوه مدیریت در پایپ‌لاین پروژه
تعداد مشاهدات خام و تمیز (Clean Observations)	7,366 مشاهده (100% معتبر)	تمامی رکوردها دارای مختصات معتبر، تاریخ صحیح، وضعیت وحشی (`captive=0`) و فایل تصویر سالم روی دیسک هستند.
توزیع منطقه‌ای (North America vs. Europe)	آمریکا: 3,571 | اروپا: 3,795	استفاده از آمریکای شمالی برای آموزش/اعتبارسنجی/آزمون داخلی و قفل کردن کل اروپا برای آزمون تغییر دامنه (Geographic Shift).
تعداد کل رکوردهای تصویر و نرخ چندتصویری	15,595 عکس (میانگین 2.12)	**54.44% از مشاهدات دارای ۲ تا ۲۰ تصویر** از زوایای مختلف یک قارچ واحد هستند (ضرورت تقسیم در سطح مشاهده).
تعداد مشاهده‌گران یکتا (Unique Observers)	4,631 کاربر یکتا	توزیع قانون توان: ۱۰٪ کاربران پرکار **35.51%** کل مشاهدات را ثبت کرده‌اند (ضرورت تقسیم در سطح مشاهده‌گر).
مقادیر گمشده دقت مکانی (`positional_accuracy`)	1,521 رکورد (20.65%)	نبود مقدار تصادفی محض نیست؛ حفظ رکورد، ساخت متغیر نشانگر گمشدگی (`missing_flag`) و جایگذاری با میانه آموزش در فاز ۲.
مقادیر گمشده ساعت دقیق (`time_observed_at`)	197 رکورد (2.67%)	تاریخ روز (`observed_on`) در ۱۰۰٪ رکوردها کامل است؛ ساخت نشانگر گمشدگی ساعت و جایگذاری ساعت با میانه آموزش.
خطای مکانی شدید (`positional_accuracy > 10 km`)	69 رکورد (0.94%)	پرچم‌گذاری با متغیر `is_high_gps_uncertainty = 1` و سقف‌گذاری (Winsorization) در ۲۵ کیلومتر در پایپ‌لاین فاز ۲.
توزیع طبقات سمیت (Toxicity Breakdown)	خوراکی: 3,727 | سمی/کشنده: 3,639	شامل 3,727 مشاهده خوراکی، 2,193 مشاهده کشنده (`Deadly_Toxic`) و 1,446 مشاهده غیرخوراکی/سمی خفیف.

۵. تحلیل اکتشافی تک‌متغیره، چندمتغیره و توزیع دنباله بلند (EDA & Long-Tail)

- **تحلیل عدم توازن و دنباله بلند (Long-Tail Distribution):** بررسی فراوانی ۴۰ گونه در مجموعه داده نشان می‌دهد که تعداد مشاهدات بین حداکثر 200 مشاهده (برای گونه‌های پرتکرار) تا حداقل 100 مشاهده (برای گونه‌های کم‌نمونه‌تر نظیر *Agaricus xanthodermus* و *Amanita bisporigera*) متغیر است (نسبت عدم توازن کلی 2.0x و ضریب جینی 0.0718؛ و در درون زیرمجموعه آموزش آمریکای شمالی نسبت عدم توازن بسیار شدیدتر و بیش از 10x برای گونه‌های نادر قاره‌ای است). بر اساس چندک‌های تجربی فراوانی در داده آموزش، گونه‌ها به سه لایه `Head (Frequent)`، `Medium` و `Tail (Rare)` تفکیک شدند تا عملکرد مدل‌ها روی گونه‌های کم‌نمونه به دقت رصد شود.

- **الگوهای مکانی-زمانی و فنولوژی رویش (Spatiotemporal Patterns):** تحلیل چندمتغیره «خانواده زیستی × ماه مشاهده» (در نمودار `fig3_spatiotemporal_multivariate_patterns.png`) نشان می‌دهد که خانواده‌های بهاره مانند *Morchellaceae* (مورل خوراکی) و *Discinaceae* (مورل کاذب کشنده) بیش از ۸۰٪ مشاهداتشان در ماه‌های آوریل و مه (ماه‌های ۴ و ۵) متمرکز است، در حالی که خانواده‌های *Boletaceae*، *Amanitaceae* و *Cantharellaceae* اوج رویش خود را در اواخر تابستان و پاییز (اوت تا نوامبر) تجربه می‌کنند.
- **تغییر دامنه عرض جغرافیایی بین قاره‌ها:** مقایسه توزیع عرض جغرافیایی نشان می‌دهد که مشاهدات قاره اروپا (میانگین عرض جغرافیایی 50.8° N) نسبت به آمریکای شمالی (میانگین 41.2° N) به طور معناداری در عرض‌های شمالی‌تر قرار دارند. این یافته ثابت می‌کند که انتقال از آمریکای شمالی به اروپا علاوه بر تغییر طول جغرافیایی، یک **تغییر توزیع در عرض جغرافیایی (Latitudinal Shift)** نیز ایجاد می‌کند.
- **تداخل در گروه‌های هم‌شکل (Look-Alike Guilds):** نمودار `fig4_lookalike_risk_guilds.png` تایید می‌کند که در تمامی گروه‌های ظاهری (نظیر قارچ‌های سفید تیغه‌دار و قارچ‌های نارنجی قیفی)، گونه‌های خوراکی و کشنده هم‌پوشانی مستقیم دارند.

۶. ممیزی خطر نشت اطلاعات (Data Leakage) و ارزیابی خط مبنای اولیه

یکی از مهم‌ترین الزامات مسیر ج، شناسایی و حذف منابع نشت اطلاعات در هنگام طراحی تقسیم داده (Split Design) و کمی‌سازی خطر استفاده ناخواسته از مکان و زمان به عنوان میان‌بر پیش‌بینی (Shortcut) است. ما چهار آزمایش کمی بر روی داده‌های واقعی اجرا کردیم (خلاصه در `fig5_leakage_and_shortcut_baselines.png`):

بخش آزمایش (Leakage & Baseline Audit)	روش / مدل مورد بررسی	نتیجه کمی بر روی داده واقعی	تفسیر تحلیلی و پیامد برای طراحی فازهای ۲ تا ۵
ممیزی نشت ۱: تقسیم تصادفی عکس‌ها	`Naive Photo-Level Split (80/20)`	**71.50% نشت اطلاعات!**	از آنجا که ۵۴.۴٪ مشاهدات چندتصویری هستند، در تقسیم تصادفی عکس‌ها، ۷۱.۵٪ عکس‌های تست دارای عکس همزاد از همان قارچ در داده آموزش هستند.
ممیزی نشت ۲: تقسیم تصادفی مشاهدات	`Naive Observation Split (80/20)`	**42.19% هم‌پوشانی عکاس**	تقسیم تصادفی مشاهدات باعث می‌شود ۴۲.۲٪ مشاهدات تست توسط عکاسانی ثبت شده باشند که در آموزش حضور دارند و **17.85%** در فاصله زیر ۱ کیلومتری داده آموزش باشند.
طرح استاندارد منتخب مسیر ج	`Observer-Grouped Split`	**0.00% نشت مشاهده و عکاس**	با گروه‌بندی بر اساس `observer_id`، هیچ مشاهده یا عکاسی بین مجموعه‌های آموزش، اعتبارسنجی و آزمون مشترک نیست.
خط مبنای ۱: کلاس اکثریت	`Majority Class Dummy`	دقت: 1.08% | Macro-F1: 0.05%	در حضور ۴۰ کلاس (شانس تصادفی 2.50%)، پیش‌بینی کلاس اکثریت کاملاً ناکارآمد است.
خط مبنای ۲: میان‌بر فصل و عرض جغرافیایی	`Season + Latitude Tree`	دقت: 15.49% | Macro-F1: 13.79%	صرفاً با دانستن تاریخ و عرض جغرافیایی (بدون دیدن تصویر!)، دقت به بیش از ۶ برابر شانس تصادفی می‌رسد (وجود همبستگی قوی اکولوژیکی).
خط مبنای ۳: میان‌بر کامل GPS و سقوط در اروپا	`Full GPS + Season Shortcut`	آمریکا: **21.53%** ← اروپا: **4.06%**	مدل متکی به طول و عرض جغرافیایی در آمریکای شمالی ۲۱.۵۳٪ دقت می‌گیرد، اما هنگام انتقال به قاره اروپا به ۴.۰۶٪ سقوط می‌کند (اثبات خطر Shortcut مکانی).

جمع‌بندی

نتایج فاز اول به وضوح نشان داد که اولاً تقسیم داده باید الزاماً به صورت `Observer-Grouped` انجام شود تا از نشت ۷۱.۵ درصدی تصاویر و ۴۲.۲ درصدی عکاسان جلوگیری گردد؛ و ثانیاً فراداده‌های مکانی خام اگرچه در داخل یک قاره قدرت پیش‌بینی بالایی (۲۱.۵۳٪) دارند، اما تحت تغییر دامنه جغرافیایی به شدت شکننده‌اند (سقوط به ۴.۰۶٪).